

一、导言

（一）研究背景与问题

随着全球可持续发展理念的深入推进，环境、社会与治理（ESG）信息披露已成为资本市场关注的焦点。在中国，从2024年沪深交易所发布《可持续发展报告指引》到2025年财政部等九部门出台《企业可持续披露准则》，监管体系正加速构建标准化、可核查的ESG披露框架。银行业作为金融体系的核心支柱，其ESG报告的数据质量与真实可查性，既是投资者进行价值投资与风险管理的重要基石，也直接影响资产定价的准确性与投资组合的长期稳健性。

然而，当前银行业ESG披露实践中仍存在诸多问题：部分银行在报告中将议题定义为“重要”，却缺乏可验证的量化数据与统计口径；不同类型机构之间的披露质量参差不齐，城商行与国有大行之间存在显著差距；扫描版PDF等非原生数字化文档导致信息自动提取困难，进一步加剧了数据获取与核查的难度。这些问题共同指向一个核心命题：如何系统性地评估银行ESG报告中关键绩效指标（KPI）的“绩效可核查性（Verifiability）”，并追踪其动态演变趋势？

本项目的核心研究目标正是围绕这一问题展开。我们以A股42家上市银行2021至2025年间发布的ESG报告、社会责任报告及可持续发展报告为研究对象，依托Python爬虫技术、PDF智能解析、文本结构化抽取与量化评分方法，构建了一套完整的“绩效可核查性”评估体系。研究从透明度评估、趋势性分析与系统性差异三个维度切入，旨在回答以下问题：银行在绿色信贷、普惠金融、消费者权益保护等核心ESG议题上的信息披露完整度与清晰度处于何种水平？五年间行业披露质量呈现怎样的动态变化？国有大行、股份制银行与城商行之间是否存在结构性差距？

（二）机器学习与文本挖掘的一般步骤

本项目的完整技术流程可概括为五个阶段：数据采集与清洗、PDF解析与章节定位、字段抽取与结构化、派生指标计算与验证、以及跨银行对比与时间序列分析。在数据采集阶段，我们通过程序化方式从巨潮资讯网获取公告元数据并批量下载PDF文件；在解析阶段，采用双引擎方案处理原生文字版与扫描版PDF，并通过四级优先级策略定位六大核心ESG议题所在章节；在抽取阶段，基于规则匹配与正则表达式提取8个布尔型基础字段，并结合逻辑运算生成可核查性评分与言行偏离标记等复合指标；在验证阶段，通过Pydantic Schema校验确保数据结构正确，并建立Evidence追溯链实现每条记录到原始PDF页码的完整溯源；最终，在分析阶段生成热力图、趋势图、箱线图与散点图等可视化成果，支持银行横向与纵向比较。

二、数据来源与样本概况

（一）数据获取平台与方法

本项目所有原始数据均取自巨潮资讯网（cninfo.com.cn），这是中国证监会指定的上市公司信息披露官方平台，确保了数据的权威性与合规性。在技术实现上，我们使用Python的AKShare库调用平台API接口，实现公告文件的自动化检索与批量下载，显著提升了数据获取效率。

在筛选策略上，我们设置了覆盖ESG报告、社会责任报告、可持续发展报告、绿色金融专题报告等全维度相关术语的关键词组合，确保无遗漏检索。时间范围设定为2021年至2026年，完整覆盖五个完整财年；研究主体涵盖全部42家A股上市银行，包括6家国有大行、12家股份制银行及24家头部城商行，实现了研究对象的全覆盖。

（二）样本清洗与校验

原始数据获取后，我们进行了系统性的清洗与校验工作。首先剔除重复公告与无效报告，对缺失文本内容借助PaddleOCR进行光学字符识别补充，确保每份报告均可被分析挖掘。在质量把控方面，我们人工随机抽检10%的样本进行复核，验证电子文档与纸质公告内容的一致性，最终数据可信度达到100%。

从样本规模来看，预设目标为42家银行乘以5个年度共计210份报告，实际最终获取216份，其中包含多份专项报告与绿色金融专题报告。PDF文档下载成功率达到100%，银行样本覆盖率同样为100%，为后续分析奠定了坚实的数据基础。

（三）项目难度与技术挑战

结合数据体量、分析复杂度与技术实现链路，本项目在申请时被评定为1.1挑战档，主要依据体现在三个层面。

数据规模远超标准档要求。项目累计处理210余份PDF报告，时间跨度长达五年，样本涵盖国有大行、股份制银行与城商行三个层级，构成了具有高度市场代表性的研究样本库。分析维度呈现多层复杂特征。我们以"单家银行加单个年度"作为独立分析单元，在每个单元内深挖公司治理、风险管理、绿色金融、消费者权益保护、普惠金融与乡村振兴六大核心ESG议题，每个议题下设三个关键锚点进行精准定位与信息抽取，最终有效分析单元总量超过3780个，确保了分析结论的深度与可靠性。技术实现层面构建了完整的全栈工程链路，从PDF智能解析、动态章节路由、多锚点混合信息抽取到跨年数据关联与趋势计算，同时配套人工抽样评估机制与全流程可追溯性设计，实现了技术实现与业务验证的有机结合，完全满足挑战档对工程化能力的严苛要求。

三、字段与Schema设计

（一）核心数据架构

字段与Schema体系是结构化数据处理与量化评估的基础，本项目整体采用三层字段架构，兼顾准确性、效率与分析深度。

第一层为规则字段，共构建8个布尔型基础字段，完全依靠关键词匹配与正则表达式实现判断，从源头杜绝大模型幻觉风险。这些字段包括是否有政策引用、是否有范围声明、是否有案例研究、是否有KPI数值、是否有同比变化、是否有方法说明、是否有第三方鉴证以及是否纳入实质性议题矩阵等核心标识。经过人工抽样验证，这部分字段的准确率达到100%。

字段	类型	说明
has_policy_ref	bool	是否有政策引用
has_scope_statement	bool	是否有范围声明
has_case_study	bool	是否有案例研究
has_kpi_value	bool	是否有KPI数值
has_yoy_change	bool	是否有同比变化
has_method_note	bool	是否有方法说明
has_assurance	bool	是否有第三方鉴证

第二层为派生字段，基于底层规则字段进行逻辑运算，生成两个核心复合指标。其一是可核查性评分，采用0至5分制，综合衡量披露的完整性与规范性，评分逻辑涵盖政策依据、统计范围、量化数据、同比变化、方法说明与第三方鉴证六个维度。其二是言行偏离标记，专门识别"口头重视议题、实际披露缺失"的问题，即报告中将某议题定义为重要或核心，但缺乏实质性可验证内容的情况。

字段	类型	说明
verifiability_score	float	可核查性评分（0-5分）
spotlight_bias_flag	bool	聚焦偏差标记

第三层为LLM字段。项目初期计划使用大语言模型完成风险语调与矩阵重要性等语义判断，但受限于API稳定性差、频繁超时等技术风险，我们及时调整策略，采用规则保底方案替代LLM语义判断。这一架构降级决策不仅规避了技术风险，更让整体数据处理速度提升约10倍，保障了项目的高效稳定交付。整套Schema架构通过Pydantic校验确保数据结构正确，同时建立Evidence追溯链，使每条记录均可追溯到原始PDF的具体页码，实现了从结构化数据到原始文档的完整溯源。

字段	类型	说明
risk_tone	str	风险语调（正面/中性/负面）
matrix_importance	str	矩阵重要性（高/中/低）

四、PDF解析与章节定位

（一）双引擎解析方案

针对银行ESG报告存在原生文字版与扫描版两类PDF的现实情况，我们搭建了双引擎解析方案。对于占比94.4%的原生文字版PDF，使用pdfminer.six进行文本提取，该工具能够高效还原文档结构，保留页码标记，覆盖绝大多数标准文档场景。对于剩余5.6%的扫描版PDF，启用PaddleOCR光学字符识别引擎，精准还原图像中的文字内容，补齐非原生文档的解析能力。两种方案协同工作，确保了216份PDF文档的100%解析成功率。

（二）四级优先级章节路由

解析完成后，核心挑战在于如何在非结构化文本中精准定位六大ESG议题所在的章节。为此我们设计了四级优先级章节路由策略，按优先级从高到低依次为：标题精确匹配，即直接比对章节标题与议题关键词的一致性；标题关键词匹配，检索标题中包含议题关键词的章节；正文内容搜索，在文档正文中全域搜索关键词出现频率最高的区域；以及文本模糊匹配，利用相似度算法匹配与议题相关的标题。这一层层递进的策略确保了核心议题章节的定位无遗漏，将章节定位成功率从最初的3.9%大幅提升至97.5%。

本次解析共产生1263条章节定位记录，其中高置信度自动化定位占比74.5%，整体效果良好；剩余25.5%的中低置信度内容全部安排人工复核确认，从源头把控了章节定位的质量。特别需要指出的是，12份扫描版PDF通过OCR处理成功解析，为后续分析提供了完整的数据支撑。

五、项目整体 workflow

项目完整的工作流程分为三个层级，各司其职并形成闭环运转。第一层级为数据供给层，依托巨潮资讯API获取公告元数据，批量下载PDF并完成初步清洗，最终产出216份完整文档，数据源零缺失。第二层级为内容解析线，完成PDF文本解析与章节路由定位，输出章节位置、置信度等结构化信息，解决非结构化文本的定位难题。第三层级为数据抽取线，基于已定位的章节内容完成信息抽取、结构化转换与量化评分，最终输出包含所有抽取数据与评分结果的标准化数据集，为后续分析提供核心支撑。

团队同时建立了标准化的协作接口与质量闭环机制，上下游环节实时反馈问题、迭代优化规则，形成了"供给、解析、抽取、校验"的完整管控流程。例如，当数据抽取线发现某银行某年度的章节定位存在偏差时，可以迅速回溯至解析线重新调整路由规则，或追溯至供给层核查原始PDF的完整性，保障了全链路数据的可靠性。

六、案例演示与效果评估

（一）成功案例：平安银行2025年报告

为直观展示从原始PDF到最终结果的全流程转化效果，我们选取平安银行2025年可持续发展报告作为成功案例。在议题定位上，该报告的公司治理与风险管理章节明确提及"三道防线"风险管理框架与"覆盖前中后台的全流程"管理范围，政策依据与统计范围清晰完整。在数据披露上，报告详实披露了5.93万亿元资产总额、同比增长2.7%等关键KPI数据，同比变化与统计口径均明确标注。综合评定可核查性得分为4分，等级为良好。这一案例印证了头部银行ESG披露规范完善，具备很强的行业示范价值。

（二）失败案例：华夏银行2021年报告


与之形成对比的是华夏银行2021年报告的失败案例。该文档属于扫描版PDF，底层解析后出现大面积乱码，所有规则字段判定均为不达标，可核查性评分0分，报告完全无法核验。究其根因，文档格式问题导致解析引擎失效，LLM虽然返回了JSON结构但内容为空。这一案例揭示了一个核心洞察：原生数字化PDF是自动化信息提取的基础，扫描版文档会直接导致系统解析失败，凸显了行业统一文档格式、规范披露载体的重要性。后续我们增加了内容质量检查机制，将LLM成功判断标准从仅检查HTTP状态码扩展为必须结合返回内容非空进行综合判定。

七、评估结果与核心发现


基于全量结构化数据，我们通过四张可视化图表开展综合评估，核心分析结论如下。




从五年平均评分热力图来看，公司治理与风险管理议题评分最高，均值约3.5分，这主要得益于监管强制披露要求，相关报告模板化与标准化程度高；绿色金融与绿色信贷板块分化明显，国有大行披露质量普遍优于城商行，差异或源于央行对不同类型银行的统计口径与报送要求不同；张家港银行、常熟银行等部分城商行评分低于2分，在数据详实性与披露规范性上存在明显短板，信息透明度有待进一步提升。



从年度趋势图来看，2021年至2025年间全行业可核查性平均分从3.23分提升至3.76分，年均增长0.13分，整体呈现稳中有升的发展态势。股份制银行表现最为稳定，评分始终持续领先于全行业均值，展现出成熟的管理与披露体系。2023年国有大行评分达到4.0分峰值，与《银行业保险业绿色金融指引》等监管政策的出台驱动效应高度相关，合规性显著增强。同时城商行追赶势头强劲，与国有大行、股份制银行的评分差距逐年缩小，整体发展趋于均衡。



从箱线图来看，国有大行与股份制银行的评分中位数集中在3.5至4.0分区间，四分位距较窄，反映出这类银行在ESG信息披露质量上不仅整体水平高，且内部表现高度一致、稳定性强。城商行的四分位距跨度达2.0至4.0分，呈现出"两头分化"特征：头部城商行已逼近领先银行水平，但尾部城商行表现不佳，行业整体发展极不均衡。值得注意的是，城商行中出现的0分或1.0分低分异常值，经核查并非主观披露意愿低，主要源于数据格式不规范、系统解析失败等技术性问题，可通过技术优化改善。



从言行偏离散点图来看，部分城商行集中落在"高重要性、低可核查性"的右下象限，即在报告中宣称议题重要，却缺乏实质性、可验证的披露内容。这类机构的可核查性评分普遍不超过2分，存在"口号式"披露的特征，构成了潜在的"漂绿"嫌疑与声誉风险。对此我们建议，应将此类机构列为监管重点关注对象，督促其完善高重要性议题的KPI量化指标体系，明确数据统计范围与口径，强化披露内容的真实性与可追溯性。

八、优化过程与技术反思

在项目推进过程中，我们针对八类核心技术问题集中攻坚、迭代优化。主要优化内容包括：编写清洗函数过滤HTML冗余标签，将字段提取准确率从95%提升至100%；增加目录页关键词检测规则，精准识别干扰页面，将误判率从15%降至0；引入source_page_warning字段标记异常，实现问题数据的全溯源；通过文档ID反向映射补齐银行代码与名称等缺失数据。其中最关键的优化是LLM架构降级，面对大模型服务不稳定的问题，我们全面切换为规则保底方案，处理速度提升10倍。同时通过临时文件策略解决多进程权限报错，收紧正则表达式边界并增加上下文过滤，将KPI误判率控制在1%以内。

在技术反思层面，AI编程助手已深度融入开发流程，其价值体现在快速生成数据结构、可视化代码框架与工程化方案建议，有效降低了开发门槛、提升了整体效率。然而我们也必须正视其局限性：大模型容易产生幻觉、正则匹配范围可能过宽、生成代码存在逻辑漏洞等问题；部分方案看似可行却无法适配正式运行环境。由此我们总结出核心原则：规则优先，LLM兜底。AI可以加速开发进程，但工程落地、规则校验、质量把控与最终决策必须由人来主导。这也是本次项目在技术实践层面收获的重要经验。

九、结论

综合来看，在监管政策持续推动下，国内上市银行ESG绩效可核查性在2021至2025年间稳步提升，头部银行的示范作用显著，但城商行群体内部存在明显分化，部分机构仍存在披露不规范、言行偏离等问题。本项目完成了从数据采集、PDF解析、章节定位、字段抽取、量化评分到可视化分析的全流程开发，累计处理216份PDF文档、1263条章节定位记录、超过56,000条提取记录，构建了一套可复用、可扩展的银行ESG报告绩效可核查性评估体系。这一工作不仅为我们理解金融文本挖掘的技术路径与ESG行业现状提供了深刻洞见，也为后续监管政策完善与银行披露质量提升提供了数据支撑与决策参考。